

Universidad de Costa Rica

Herramientas de Ciencia de Datos I

Proyecto grupal,

Segundo avance

Grupo 6

Estudiantes:	**Carné:**
Priscilla Ramírez Ramírez	C4I820
Santiago Jara Vargas	C5G155
Luis Alfredo Odio Sanabria	C5H973
Sebastián Aguilar Pineda	C5C149
Andrés Francisco Torres Moraga	C5K247

---

21 de septiembre, 2026

Primer Avance

Ideas propuestas

1. Analizar la medida en que el presupuesto de producción y el género cinematográfico de una película determinan el éxito que esta tiene en taquilla, y en la recepción del público y la crítica en películas estrenadas en la última década.

2. ¿Qué hace que un videojuego sea exitoso? (Analizar la plataforma para la que sale, ventas, género, puntuación, región, entre otros).

3. ¿Dónde vivir? Índice mundial personalizado de calidad de vida. Hacer una aplicación interactiva que determine cuáles son los mejores países para vivir según las preferencias de cada persona. El usuario asignaría importancia a factores (seguridad, costo de vida, medio ambiente, salud, etc) y con eso la aplicación crearía un ranking personalizado y lo mostraría en un mapa.

4. Análisis de datos estadísticos en la ocurrencia, magnitud y distribución geográfica de los terremotos, de manera que permita cuantificar el riesgo en una zona particular. De igual forma, determinar variables que tienen relación con una alta/baja cantidad esperada de terremotos en la zona.

5. Cómo se relacionan distintas variables (PIB per cápita/inversión en educación/calidad educativa pruebas pisa/temperatura) con los tiempos de resolución de cubos de Rubik en las competencias de la WCA

Selección del tema

Ideas rechazadas:

La idea número 1 fue rechazada porque resultó ser mucho más amplia de lo inicialmente pensado, lo que dificulta el análisis de datos de forma precisa. Llegamos a la conclusión de que el éxito de una película incluye muchas más variables que solo su presupuesto, pues este podía estar repartido en muchas variables que podrían afectar el éxito, como lo pueden ser el marketing, la producción, el elenco, etc. Además, variables como la fecha de estreno y la competencia en taquilla pueden llegar a ser muy influyentes. Por otro lado, lo que respecta a la recepción del público y la crítica varía mucho dependiendo de dónde se recolecten los datos, por lo que esto lo convierte en una variable poco fiable al analizar datos, por lo que comparar distintas películas a lo largo de la década puede ser una tarea muy complicada.

Se rechazó la idea número 5 debido a que no llamó la atención de la totalidad del grupo. Del mismo modo, se cautivo más la atención la propuesta ganadora y está en parte usará factores similares para el análisis entonces, en parte se puede considerar la propuesta número 5 como una parte que se puede englobar en la opción escogida.

De la misma manera, la idea número 2 no fue escogida por el grupo porque a pesar de que fue aceptada por la mayoría del grupo y era un tema de interés, e incluso encontramos bases de datos con la mayoría de elementos que íbamos a analizar perdió a votación contra contra la idea ganadora más que todo por el resultado final que está proponía, ya que a pesar de que se podía hacer un buen análisis con respecto a distintos factores de los videojuegos, no se nos ocurrió una forma interactiva lo suficientemente atractiva como para continuar con esta idea; se vio opacada por el potencial del resultado final de la idea que terminó ganando en votación

Finalmente, se ha descartado la idea 4. Si bien fue del agrado de múltiples integrantes del grupo, ya que presentaba un potencial de desarrollo extenso y se relacionaba con situaciones presentes en nuestra realidad, no fue particularmente favorecida por la mayoría. Este tema presenta demasiados enfoques posibles, por lo cual puede ser difícil acotarlo para llevar a cabo un proyecto, al igual que buscar información relevante para el hipotético tema específico escogido. También, la falta de ideas claras para su desarrollo hizo que la alta generalidad del tema desalentara un trabajo en torno a este, mientras que la idea seleccionada no contaba con estos problemas.

Idea seleccionada:

Se seleccionó la propuesta "¿Dónde vivir?" porque, en comparación con las demás ideas, ofrece una mayor variedad de variables y posibilidades de análisis, además de permitir integrar información proveniente de distintas fuentes. A diferencia de propuestas como películas, videojuegos o terremotos, donde el análisis se concentra principalmente en explicar o visualizar un fenómeno, esta idea permite utilizar los datos para generar un resultado diferente según las preferencias de cada usuario. Además, incorporar tanto los beneficios de vivir en cada país como los costos o compromisos asociados, por ejemplo, impuestos y costo de vida, permite realizar un análisis más completo y con mayor profundidad. Finalmente, se consideró que era la propuesta que mejor permitía aplicar de manera conjunta los principales contenidos del curso, especialmente limpieza, transformación y visualización de datos, y que tenía mayor potencial para convertirse posteriormente en una aplicación interactiva útil y atractiva.

Bibliografía

Numbeo. (2026). *Cost of living index by country 2026*. Consultado el 27 de agosto de 2026, desde https://www.numbeo.com/cost-of-living/rankings_by_country.jsp?title=2026

Organisation for Economic Co-operation and Development. (s.f.). *Global Revenue Statistics Database*. Consultado el 27 de agosto de 2026, desde https://www.oecd.org/en/data/datasets/global-revenue-statistics-database.html

Trading Economics. (s.f.). *Tasa de impuesto a la renta de las personas - Lista de países*. Consultado el 27 de agosto de 2026, desde https://es.tradingeconomics.com/country-list/personal-income-tax-rate

United Nations Development Programme. (s.f.). *Human Development Data Center*. Consultado el 27 de agosto de 2026, desde https://hdr.undp.org/data-center

World Bank. (2026). *World Bank Open Data: GDP per capita (current US$)*. Consultado el 27 de agosto de 2026, desde https://datos.bancomundial.org/indicador/NY.GDP.PCAP.CD?most_recent_value_desc=true

World Bank. (s.f.). *Indicator API Queries*. Consultado el 27 de agosto de 2026, desde https://datahelpdesk.worldbank.org/knowledgebase/articles/898599-indicator-api-queries

World Happiness Report. (s.f.). *World Happiness Report*. Consultado el 27 de agosto de 2026, desde https://worldhappiness.report/

World Health Organization. (s.f.). *Global Health Observatory*. Consultado el 27 de agosto de 2026, desde https://www.who.int/data/gho

Segundo avance

Para este avance reunimos los datos más recientes encontrados para poder en el futuro poder analizar el país ideal para una persona bajo sus gustos, preferencias y posibilidades:

-PM2.5: mide la concentración anual de particulas PM2.5 para evaluar la calidad del aire, medida en microgramos por metro cubico.

-Tasa de Homicidios: Homicidios intencionales por cada 100 mil habitantes.

-PIB per capita: Mide la producción interna bruta sobre la cantidad de habitantes.

-Desempleo: Proporción de la fuerza laboral que no tiene trabajo, pero se encuentra disponible y buscando empleo.

-Esperanza de vida: esperanza de vida a la hora de nacer de distintos países alrededor del mundo.

-Años de escolaridad: Datos de escolaridad en adultos de 25 años de edad en adelante.

-Indice de costo de vida: comparación directa entre los precios de la ciudad de Nueva York y las de cada país.

-Indice de alquiler: compara el precio del alquiler de la ciudad de Nueva York y las de cada país.

Data frame final

El data frame final conserva exclusivamente los países de la base ambiental utilizada para evaluar el PM2.5. Cuando alguno de estos no posee información para un indicador, el valor se mantiene como `NA`. Para que las tablas se pudieran apreciar correctamente lo que hicimos fue dividir en dos la tabla final de manera que la columna indicadora fuera la del país correspondiente al dato

Tabla 1. Medio ambiente, seguridad y economía

Table 1: Medio ambiente, seguridad y economía

Pais	PM25	Tasa.homicidios	PIB.per.capita	Desempleo
Chad	91.8	NA	980.67	1.05
Bangladesh	78.0	2.34	2593.42	3.63
Pakistan	73.7	4.33	1479.48	5.49
D.R. Congo	58.2	NA	692.89	4.42
India	50.6	2.82	2591.99	4.17

Tabla 2. Salud, educación y costos

Table 2: Salud, educación y costos

Pais	Esperanza.de.vida	Anios.escolaridad	Indice.costo.vida	Indice.alquiler
Chad	55.24	2.33	NA	NA
Bangladesh	74.93	6.79	24.89	2.71
Pakistan	67.80	4.32	18.47	2.94

D.R. Congo	62.07	7.38	NA	NA
India	72.24	6.88	22.17	6.21

Cantidad de filas y columnas:

```
[1] 138
```

```
[1] 9
```

Tipos de variables:

```
'data.frame':   138 obs. of  9 variables:
 $ Pais             : chr  "Chad" "Bangladesh" "Pakistan" "D.R. Congo" ...
 $ PM25             : num  91.8 78 73.7 58.2 50.6 46.3 42.8 41 40.8 40.3 ...
 $ Tasa.homicidios  : num  NA 2.34 4.33 NA 2.82 ...
 $ PIB.per.capita   : num  981 2593 1479 693 2592 ...
 $ Desempleo        : num  1.05 3.63 5.49 4.42 4.17 ...
 $ Esperanza.de.vida: num  55.2 74.9 67.8 62.1 72.2 ...
 $ Anios.escolaridad: num  2.33 6.79 4.32 7.38 6.88 ...
 $ Indice.costo.vida: num  NA 24.9 18.5 NA 22.2 ...
 $ Indice.alquiler  : num  NA 2.71 2.94 NA 6.21 NA 4.03 7.25 9.5 NA ...
```

Note que todas las columnas, excluyendo la de país son de tipo numérica, ya que lo que buscamos es poder medir distintos parámetros de los países con el objetivo de ser más precisos a la hora de hacer una recomendación

Valores faltantes

Cantidad de valores `NA` por variable:

```
            Pais             PM25   Tasa.homicidios    PIB.per.capita
               0                0               14                 4
       Desempleo Esperanza.de.vida Anios.escolaridad Indice.costo.vida
               9                4               10                17
  Indice.alquiler
              17
```

Porcentaje de valores `NA` por variable:

```
            Pais             PM25   Tasa.homicidios    PIB.per.capita
            0.00             0.00            10.14              2.90
       Desempleo Esperanza.de.vida Anios.escolaridad Indice.costo.vida
            6.52             2.90             7.25             12.32
  Indice.alquiler
           12.32
```

Resumen descriptivo

```
       Pais          PM25        Tasa.homicidios   PIB.per.capita
 Length   :138   Min.   : 2.300   Min.   : 0.0000   Min.   :   216.2
```

```
N.unique :138   1st Qu.: 8.925   1st Qu.: 0.8404   1st Qu.:  4094.3
N.blank  :  0   Median :15.200   Median : 1.9054   Median : 13528.6
Min.nchar:  3   Mean   :18.585   Mean   : 5.9765   Mean   : 26918.9
Max.nchar: 20   3rd Qu.:23.050   3rd Qu.: 6.2240   3rd Qu.: 38065.4
                Max.   :91.800   Max.   :49.8571   Max.   :220167.2
                                 NAs    :14        NAs    :4
  Desempleo      Esperanza.de.vida Anios.escolaridad Indice.costo.vida
Min.   : 0.130   Min.   :54.63     Min.   : 2.335    Min.   : 18.47
1st Qu.: 3.274   1st Qu.:71.45     1st Qu.: 7.972    1st Qu.: 33.45
Median : 4.900   Median :76.67     Median :10.781    Median : 43.14
Mean   : 6.177   Mean   :75.76     Mean   : 9.987    Mean   : 47.45
3rd Qu.: 7.400   3rd Qu.:81.89     3rd Qu.:12.413    3rd Qu.: 57.09
Max.   :32.279   Max.   :85.39     Max.   :14.296    Max.   :133.62
NAs    :9        NAs    :4         NAs    :10        NAs    :17
Indice.alquiler
Min.   : 2.71
1st Qu.: 9.74
Median :15.08
Mean   :19.26
3rd Qu.:23.14
Max.   :91.36
NAs    :17
```

Referencias

IQAir. (2025). 2024 World Air Quality Report. IQAir.

IQAir — 2024 World Air Quality Report

Our World in Data. (2026). Homicide rate per 100,000 population [Conjunto de datos]. Datos de United Nations Office on Drugs and Crime (UNODC), con procesamiento de Our World in Data.

World Bank. (s. f.). GDP per capita (current US$) [Conjunto de datos]. World Development Indicators. Indicador NY.GDP.PCAP.CD.

World Bank. (s. f.). Unemployment, total (% of total labor force) (modeled ILO estimate) [Conjunto de datos]. World Development Indicators. Indicador SL.UEM.TOTL.ZS. Datos de International Labour Organization, ILOSTAT.

World Bank. (s. f.). Life expectancy at birth, total (years) [Conjunto de datos]. World Development Indicators. Indicador SP.DYN.LE00.IN.

United Nations Development Programme (UNDP). (2025). Human Development Report 2025 [Conjunto de datos], con procesamiento menor por Our World in Data.

Numbeo. (2024). Cost of Living Index by Country 2024 [Conjunto de datos].