UNIVERSIDAD DE COSTA RICA

FACULTAD DE CIENCIAS

ESCUELA DE MATEMÁTICAS

DEPARTAMENTO DE CIENCIAS ACTUARIALES

Curso:

Herramientas de ciencias de datos I

Avance 3

Estudiantes:

Sebastián Aguilar Pineda - C5C149

Santiago Jara Vargas - C5G155

Luis Alfredo Odio Sanabria - C5H973

Priscilla Ramírez Ramírez - C4I820

Andrés Francisco Torres Moraga - C5k247

# 1. Introducción

La elección de un país para vivir implica considerar múltiples factores que influyen en las condiciones y oportunidades de sus habitantes. Aspectos como la seguridad, la salud, la educación, el entorno ambiental, la situación económica y el costo de vida pueden tener distinta importancia dependiendo de las necesidades y preferencias de cada persona. Por ello, determinar cuál es el mejor país para vivir no constituye una decisión universal, sino un problema en el que deben evaluarse simultáneamente diferentes criterios.

Las comparaciones internacionales suelen presentar clasificaciones generales basadas en indicadores de desarrollo o calidad de vida. Sin embargo, estas clasificaciones no necesariamente reflejan las prioridades particulares de quienes las consultan. Por ejemplo, una persona puede estar dispuesta a asumir un mayor costo de vida a cambio de mejores condiciones de seguridad y salud, mientras que otra puede priorizar menores costos de vivienda y mayores oportunidades económicas. Esto evidencia la necesidad de contar con herramientas que permitan analizar los indicadores de manera conjunta y modificar su importancia relativa.

El presente proyecto busca abordar este problema mediante el análisis de ocho indicadores: tasa de homicidios, contaminación del aire por partículas PM2.5, PIB per cápita,

desempleo, esperanza de vida, años promedio de escolaridad, índice de costo de vida e índice de alquiler. Para ello, se integraron datos provenientes del Banco Mundial, Our World in Data, el Programa de las Naciones Unidas para el Desarrollo, IQAir y Numbeo, entre otras instituciones responsables de producir los indicadores originales.

A partir de esta información, se realizará un análisis exploratorio para identificar patrones, relaciones y posibles limitaciones de los datos. Posteriormente, se aplicará una metodología de imputación para tratar los valores faltantes y el método multicriterio TOPSIS para generar clasificaciones bajo diferentes escenarios de ponderación. Esto permitirá estudiar cómo cambian las posiciones de los países cuando se modifican las preferencias individuales y establecer las bases para una futura aplicación interactiva desarrollada con Shiny.

# 2. Objetivo general

Analizar comparativamente las condiciones de vida de distintos países mediante ocho indicadores socioeconómicos, ambientales y de bienestar, aplicando técnicas de análisis exploratorio de datos, imputación de datos y el método TOPSIS para generar y comparar clasificaciones según diferentes preferencias y ponderaciones de los indicadores.

# 3. Metodología

## 3.1 Obtención y preparación de los datos

Se utilizó la base de datos homogeneizada construida durante el segundo avance del proyecto, que integra ocho indicadores que provienen de distintas fuentes internacionales. Para garantizar un conjunto común de observaciones, se usó como referencia la lista de países y territorios de la base ambiental de IQAir correspondiente a 2024, excluyendo entidades adicionales presentes en las demás fuentes.

Las bases fueron integradas mediante identificadores geográficos comunes, conservando los valores faltantes como NA cuando no existía información disponible. Se priorizaron observaciones de 2024 y, en aquellos indicadores con cobertura insuficiente, se utilizaron datos anteriores según su disponibilidad. Estas diferencias temporales se consideran una limitación del análisis.

## 3.2 Análisis exploratorio de datos

Se realizó un análisis exploratorio de los ocho indicadores para examinar sus distribuciones, dispersión y posibles valores atípicos. Se utilizó estadísticas descriptivas y visualizaciones, como histogramas, diagramas de caja y gráficos de dispersión, que permitieron identificar diferencias entre países y relaciones relevantes entre variables.

Adicionalmente, se analizaron correlaciones entre los indicadores para identificar asociaciones y posibles redundancias. Estos resultados facilitaron la interpretación de las características de las variables y su discusión en cómo podrían influir en la construcción de una clasificación multicriterio. Las asociaciones encontradas se interpretarán sin atribuirles relaciones causales.

## 3.3 Tratamiento de valores faltantes

Se omitieron los países que hayan presentados 3 o más NA, esto pues ya que se considero que tienen muy poca información para ser imputados. Para el tratamiento de valores faltantes en los países no filtrados anteriormente, se implementó la técnica de imputación mediante K vecinos más cercanos (K-Nearest Neighbors Imputation, KNN), utilizando cinco vecinos (K = 5). Este método permite estimar los valores faltantes a partir de observaciones con características similares, en lugar de utilizar una media general para todos los países.

Para cada país e indicador faltante, se identificaron los cinco países estadísticamente más similares que disponían de un valor observado para dicho indicador. La similitud se determinará utilizando los restantes indicadores disponibles en ambos países, previamente estandarizados mediante la función scale() de R, con el objetivo de evitar que las diferencias entre unidades de medida influyan desproporcionadamente en las comparaciones.

Del mismo, se calculó una distancia euclidiana ajustada por la cantidad de indicadores compartidos y se seleccionaron los cinco países con menor distancia. El valor faltante fue sustituido por la media aritmética de los valores observados del indicador correspondiente en esos cinco vecinos.

El procedimiento se implementó mediante una función propia en R, utilizando exclusivamente los valores originales como referencia para evitar que las imputaciones anteriores influyen en las posteriores. Cuando no existan cinco países comparables, el valor permanecerá como NA.

Finalmente, se comparó la cantidad de valores faltantes antes y después de la imputación para evaluar su efectividad. Se reconoce que los valores imputados son estimaciones y que

su precisión depende de la similitud entre países y de la disponibilidad de información, lo cual representa una limitación para los resultados posteriores de TOPSIS.

## 3.4. Aplicación del método TOPSIS

Para generar las clasificaciones se utilizó el método TOPSIS (Technique for Order Preference by Similarity to Ideal Solution), implementado mediante la función topsis() de R. Este método permite ordenar alternativas según su cercanía a una solución ideal positiva y su distancia respecto de una solución ideal negativa.

Los países constituyen las alternativas, mientras que los ocho indicadores representaron los criterios de evaluación. Se estableció como deseable maximizar el PIB per cápita, la esperanza de vida y los años de escolaridad, y minimizar la tasa de homicidios, la contaminación PM2.5, el desempleo, el costo de vida y el alquiler.

TOPSIS normalizó los indicadores, incorpora los pesos asignados y calcula una puntuación de cercanía relativa para cada país. Las puntuaciones mayores representan alternativas comparativamente más favorables bajo los criterios y ponderaciones utilizados.

## 3.5. Escenarios de ponderación y sensibilidad

Para evaluar la influencia de las preferencias individuales, se aplicó TOPSIS utilizando diferentes escenarios de ponderación.

En primer escenario, se construyó un escenario equilibrado, en el que cada uno de los ocho indicadores tendrá un peso de 12,5 %. Posteriormente, se definieron escenarios que otorguen mayor importancia a las condiciones económicas, al bienestar general y a los costos asociados con vivir en cada país.

Se compararon las posiciones obtenidas en cada escenario para identificar países que mejoran o empeoran cuando se modifican las prioridades. Adicionalmente, se realizó un análisis de sensibilidad mediante diferentes combinaciones de pesos, con el fin de evaluar la estabilidad de las clasificaciones.

Este procedimiento permitió analizar hasta qué punto las recomendaciones dependen de las preferencias del usuario y sirvió como fundamento para desarrollar posteriormente una aplicación interactiva en la que cada persona pueda establecer la importancia que desea asignar a los indicadores.

## 3.6. Herramientas de asistencia y reproducibilidad

Para el análisis de datos y la creación de gráficos y tablas se utilizó el lenguaje de programación R (versión 4.6.1) junto con Quarto.

Con el fin de corregir errores en el código y aplicar de forma correcta el formato visual que exigen las normas de la American Psychological Association (APA 7) en los paquetes `ggplot2` y `kableExtra`, se utilizó la herramienta ChatGPT (OpenAI, 2026) como asistente técnico de programación.

Las consultas realizadas a la inteligencia artificial se limitaron únicamente al diseño visual y la edición del código de R.

# 4. Resultados

## 4.1 Análisis exploratorio de datos

El AED se realizó sobre los valores observados de los ocho indicadores, antes de imputar. Se examinaron la cobertura, las diferencias entre media y mediana, los valores extremos y las asociaciones entre indicadores. El propósito fue identificar limitaciones y compensaciones relevantes para la posterior clasificación de países y territorios mediante TOPSIS.

### 4.1.1 Cobertura y alcance de la muestra

La base integrada contiene 138 países y territorios. El código del proyecto excluye los que presentan tres o más valores faltantes; con este criterio se retienen 123 y se excluyen 15. Por tanto, los resultados siguientes describen el conjunto retenido, no la totalidad de la lista inicial.

Entre las observaciones retenidas, 109 tienen los ocho indicadores completos y 14 presentan al menos un faltante. En conjunto quedan 20 celdas sin información. La Tabla 1 permite localizar esos faltantes. La cobertura elevada expresa disponibilidad, no precisión: no garantiza actualidad, comparabilidad temporal ni ausencia de errores. Además, está condicionada por la exclusión previa de los países con menor información.

**Tabla 1**
*Cobertura y tendencia central antes de imputar*

*Nota.* Elaboración del grupo a partir de la base de datos integrada original.

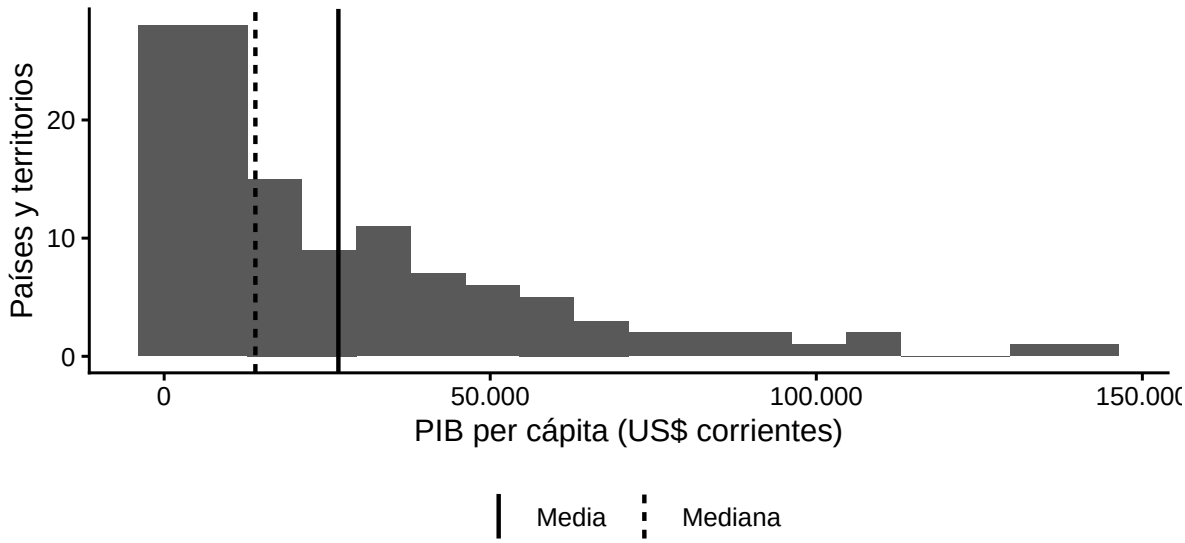
| Indicador | N | NA (%) | Media | Mediana |
|---|---|---|---|---|
| PM2.5 | 123 | 0,0 | 18,17 | 15,20 |
| Homicidios | 118 | 4,1 | 5,85 | 1,83 |
| PIB per cápita | 123 | 0,0 | 26.714,82 | 13.988,04 |
| Desempleo | 121 | 1,6 | 5,98 | 4,90 |
| Esperanza de vida | 123 | 0,0 | 76,21 | 77,20 |
| Escolaridad | 118 | 4,1 | 10,21 | 10,90 |
| Costo de vida | 119 | 3,3 | 47,57 | 43,14 |
| Alquiler | 119 | 3,3 | 19,39 | 15,09 |

### 4.1.2 Distribuciones y efecto de los valores extremos

**Unidades:** PM2.5 en microgramos por metro cúbico; homicidios por cada 100.000 habitantes; PIB per cápita en US$ corrientes; desempleo en porcentaje de la fuerza laboral; esperanza de vida y escolaridad en años; costo de vida y alquiler en puntos de índice. Las medias se calculan entre las entidades disponibles, sin ponderar por población.

El PIB per cápita tiene una media de 26.714,82 y una mediana de 13.988,04: el promedio equivale a 1,91 veces la mediana. En la Figura 1 se observa la concentración de observaciones y la prolongación hacia valores elevados. Esta separación explica por qué la media, por sí sola, no describe la situación de la mayoría de los países; se acompaña de la mediana para interpretar el valor central sin confundirlo con el ingreso de una persona.

**Figura 1**
*Distribución del PIB per cápita observado, con media y mediana*




*Nota.* Elaboración del grupo con datos del Banco Mundial.

Para identificar posibles valores atípicos se utilizan las cercas de Tukey. Se consideran potencialmente atípicos los valores inferiores al primer cuartil menos 1,5 veces el rango intercuartílico o superiores al tercer cuartil más 1,5 veces dicho rango. El rango intercuartílico corresponde a la diferencia entre el tercer y el primer cuartil; por tanto, no basta con estar fuera del intervalo entre los cuartiles para considerar una observación atípica. En el PIB per cápita, el límite superior es de 90.302,85 dólares estadounidenses. Seis países o territorios superan este valor, entre ellos Bermudas, Luxemburgo e Irlanda. Al omitir temporalmente estas seis observaciones, la media disminuye un 17,3 %, lo que evidencia su influencia sobre el promedio. Este cálculo se realiza únicamente como diagnóstico: los valores señalados no se eliminan de la base ni se modifican los rankings, y tampoco se consideran errores únicamente por su magnitud.

En homicidios, la media es 5,85 y la mediana 1,83 por cada 100.000 habitantes. Su máximo observado llega a 49,86. La diferencia entre las medidas de centro aconseja no representar la seguridad de todos los países mediante un único promedio. En TOPSIS, los extremos intervienen en los perfiles ideal y antiideal; por ello, se mantienen como información relevante, pero no se presupone que normalizar elimine su influencia.

### 4.1.3 Asociaciones y compensaciones entre indicadores

La Tabla 2 presenta tres relaciones vinculadas con el objetivo del proyecto. Spearman compara el orden de los valores; cada coeficiente se calcula únicamente con los países

que poseen ambos indicadores. Por eso se informa el número de pares disponibles y no se supone que todas las correlaciones provengan de la misma muestra.

**Tabla 2**
*Asociaciones de Spearman seleccionadas*

| Relación | N | Spearman |
|---|---|---|
| PIB / esperanza de vida | 123 | 0,888 |
| PIB / costo de vida | 119 | 0,854 |
| Costo de vida / alquiler | 119 | 0,880 |

*Nota.* Elaboración del grupo a partir de la base de datos integrada original.

El PIB per cápita y la esperanza de vida presentan una correlación de 0,888. En la base enviada, esta asociación positiva indica que los países con mayor PIB tienden a ocupar posiciones más altas en esperanza de vida. No demuestra que el PIB cause por sí solo una mayor longevidad. Para el índice, importa porque dos dimensiones distintas pueden aportar información parcialmente relacionada; sus ponderaciones deben interpretarse conjuntamente.

La asociación entre PIB y costo de vida es de 0,854 y se visualiza en la Figura A1 (ver Anexo A). En los resultados del grupo, los países con mayor PIB tienden a presentar mayores índices de costo de vida. Esto muestra una compensación relevante: priorizar un mayor PIB y priorizar menores costos puede favorecer alternativas diferentes. No equivale a medir asequibilidad, porque no se dispone del salario ni del presupuesto particular de cada usuario.

Finalmente, costo de vida y alquiler presentan una correlación de 0,880. En la base analizada, sus patrones son similares, aunque no son conceptos idénticos. Con pesos iguales, ambos criterios reciben conjuntamente el 25 % del peso nominal del modelo. Esta asociación no obliga a eliminar uno, pero sí a reconocer que la dimensión de costos está representada por dos criterios relacionados.

### 4.1.4 Implicaciones para la metodología

El AED identifica tres precauciones para interpretar los rankings: la muestra está condicionada por la disponibilidad de información, los extremos influyen en las medidas de centro y varios criterios se encuentran relacionados. La estandarización utilizada en KNN permite comparar unidades distintas, pero las imputaciones siguen siendo estimaciones. Asimismo, los datos corresponden a distintos años según el indicador; las asociaciones no representan una fotografía estricta de 2024. Estos límites justifican

interpretar TOPSIS como una comparación relativa bajo criterios y preferencias explícitos, no como una recomendación universal.

## 4.2 Resultados de la Metodología

### 4.2.1 Escenario TOPSIS con ponderaciones iguales

Los diez países con mejor desempeño relativo bajo este enfoque de pesos idénticos se detallan a continuación en la Tabla 3.

**Tabla 3**
*Diez países mejor clasificados con ponderaciones iguales*

| Posición | País | Puntuación TOPSIS |
|---|---|---|
| **1** | **Luxembourg** | **0.7878** |
| 2 | Norway | 0.7829 |
| 3 | Ireland | 0.7695 |
| 4 | Macao SAR | 0.7622 |
| 5 | Denmark | 0.7507 |
| 6 | Iceland | 0.7476 |
| 7 | Netherlands | 0.7474 |
| 8 | Germany | 0.7460 |
| 9 | Belgium | 0.7432 |
| 10 | Austria | 0.7416 |

*Nota.* Elaboración del grupo a partir de la base integrada y los resultados TOPSIS.

Como punto de referencia, se aplicó el método TOPSIS asignando un peso de 12,5 % a cada uno de los ocho indicadores. Este escenario permite comparar los países sin establecer prioridades entre los criterios y constituye la base para evaluar posteriormente los cambios producidos por diferentes preferencias individuales.

Los resultados muestran que Luxemburgo ocupa la primera posición, con una puntuación TOPSIS de 0,7878, seguido de Noruega (0,7829) e Irlanda (0,7695). Asimismo, destacan Macao, Dinamarca, Islandia, Países Bajos, Alemania, Bélgica y Austria, que completan las diez primeras posiciones.

Se observa un predominio de países europeos entre las alternativas mejor clasificadas. No obstante, las puntuaciones de algunos países son muy similares. Por ejemplo, la diferencia entre Luxemburgo y Noruega es de aproximadamente 0,0048, mientras que Islandia y Países Bajos presentan puntuaciones prácticamente iguales. Esto evidencia que pequeñas diferencias en la puntuación pueden traducirse en cambios de posición.

Es importante señalar que esta clasificación refleja el desempeño relativo de los países según los ocho indicadores seleccionados y sus ponderaciones, por lo que no representa una valoración absoluta de sus condiciones de vida. En los siguientes escenarios se analizará cómo cambia este orden al modificar la importancia asignada a cada indicador.

### 4.2.2 Escenario TOPSIS diferentes ponderaciones

Por otro lado, se optó por analizar los resultados al considerar una mayor ponderación para ciertas variables. Esto se da con el objetivo de simular como las personas suelen priorizar ciertos aspectos al tomar decisiones. Se realizó esta evaluación con los aspectos de: bienestar, economía y costos, y cada resultado fue comparado con los demás y con la evaluación equilibrada.

Los resultados muestran amplias diferencias entre las clasificaciones. Luxemburgo ocupa la primera posición en el escenario equilibrado, mientras que Islandia encabeza el escenario de bienestar, Bermudas el económico y Pakistán el de costos. Es decir, diferentes preferencias producen distintos resultados, por lo cual evaluar el caso equilibrado puede no reflejar la realidad lo que realmente busca una persona en un país.

Además, algunos países presentan cambios significativos entre las evaluaciones, como se puede apreciar en la Figura B1 (ver Anexo B):: Bermudas pasa de la posición 101 en el escenario equilibrado a la primera en economía, pero baja hasta la 123 en costos, resultando en una variación máxima de 122 posiciones. Similarmente, Suiza ocupa la cuarta posición en economía y la séptima en bienestar, pero desciende hasta la 120 cuando se le da más importancia a los costos. También, Pakistán pasa de la posición 115 en el escenario equilibrado a la primera en costos.

Esto quiere decir que no existe un país "perfecto" que maximice la satisfacción a cada componente. Es más, los países que maximizan cada variable proceden de distintas regiones del mundo, por lo cual se podría teorizar sobre una posible influencia de la región geográfica de un país con su desempeño en cierto aspecto evaluado. Se puede decir que existen compensaciones entre las condiciones económicas, el bienestar y los costos asociados con vivir en cada país, pues países que sobresalen en ciertas áreas dan pobres resultados en otras.

En conclusión, los resultados respaldan la utilidad del proyecto. Se evidencia que, en lugar de recomendar un mismo país a todos los usuarios, la metodología permite adaptar el orden de las alternativas a los criterios que cada persona considere más importantes.

# Bibliografía

IQAir. (2025). 2024 World Air Quality Report. IQAir.

IQAir — 2024 World Air Quality Report

Numbeo. (2024). Cost of Living Index by Country 2024 [Conjunto de datos].

Madanchian, M., & Taherdoost, H. (2023). A comprehensive guide to the TOPSIS method for multi-criteria decision making. Sustainable Social Development, 1(1), Article 2220.

OpenAI. (2026). ChatGPT (GPT-6) [Modelo de lenguaje grande].

Our World in Data. (2026). Homicide rate per 100,000 population [Conjunto de datos]. Datos de United Nations Office on Drugs and Crime (UNODC), con procesamiento de Our World in Data.

United Nations Development Programme (UNDP). (2025). Human Development Report 2025 [Conjunto de datos], con procesamiento menor por Our World in Data.

World Bank. (s. f.). GDP per capita (current US$) [Conjunto de datos]. World Development Indicators. Indicador NY.GDP.PCAP.CD.

World Bank. (s. f.). Unemployment, total ( % of total labor force) (modeled ILO estimate) [Conjunto de datos]. World Development Indicators. Indicador SL.UEM.TOTL.ZS. Datos de International Labour Organization, ILOSTAT.

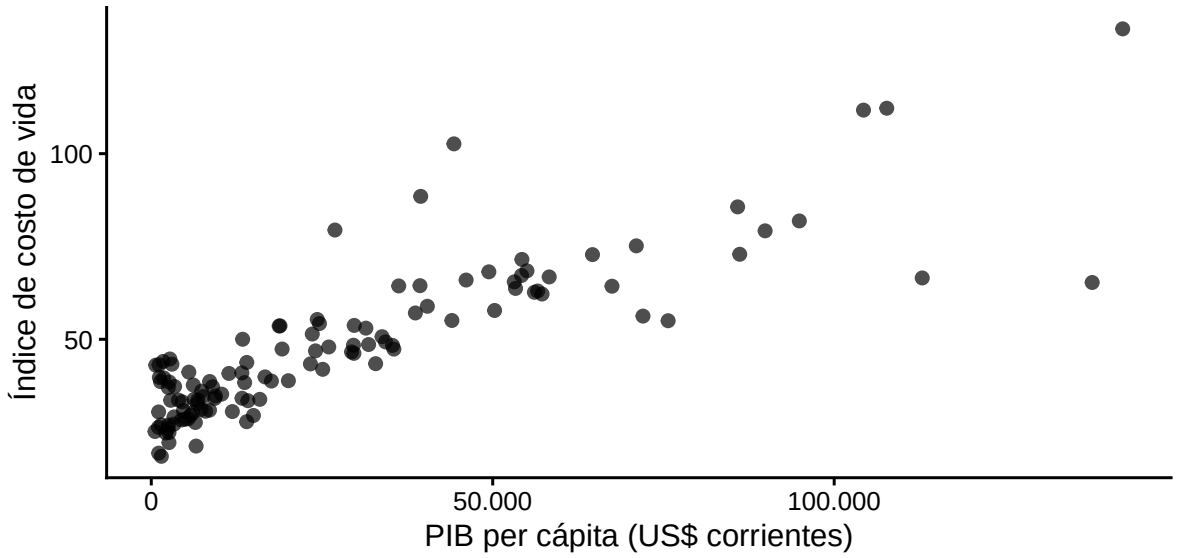
World Bank. (s. f.). Life expectancy at birth, total (years) [Conjunto de datos]. World Development Indicators. Indicador SP.DYN.LE00.IN.

# Anexos

## Anexo A: Análisis de Dispersión entre Ingresos y Costo de Vida

**Figura A1**

*PIB per cápita e índice de costo de vida*

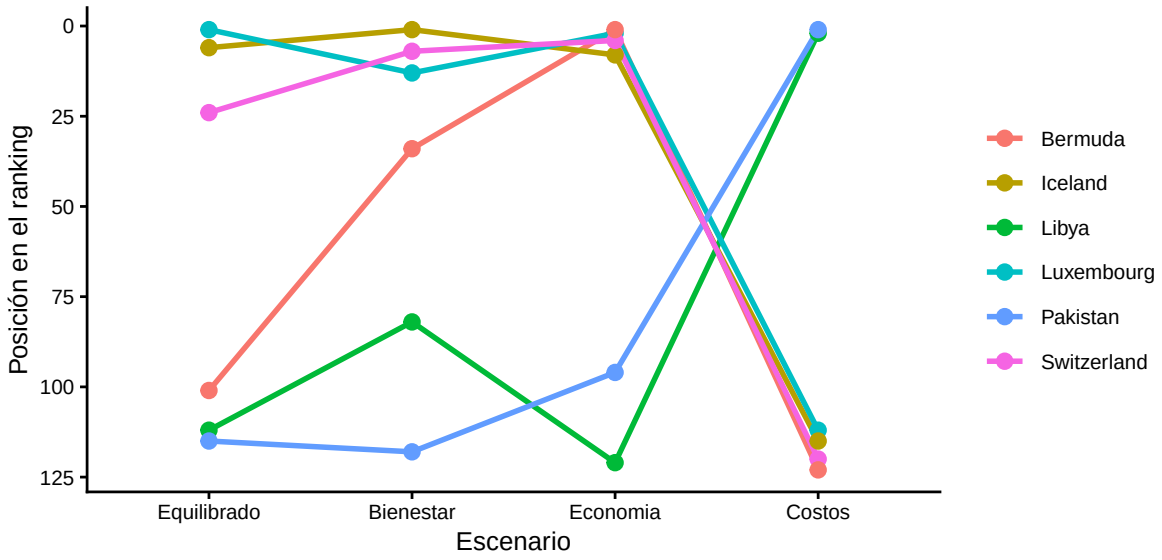



*Nota.* Relación entre el ingreso por habitante y el nivel de precios para el conjunto de países analizados. Elaboración del grupo con datos del Banco Mundial y Numbeo / IQAir.

## Anexo B: Análisis de Posiciones bajo Diferentes Ponderaciones

**Figura B1**

*Cambios de la posición de seis países mediante TOPSIS según las preferencias*




*Nota.* Elaboración del grupo a partir de la base integrada y los resultados TOPSIS bajo escenarios de sensibilidad.

**Tabla B1**

*Posiciones de los diez primeros países bajo diferentes escenarios*

| País | Equilibrado | Bienestar | Economía | Costos | Variación |
|---|---|---|---|---|---|
| Luxembourg | 1 | 13 | 2 | 112 | 111 |
| Norway | 2 | 8 | 7 | 106 | 104 |
| Ireland | 3 | 12 | 3 | 116 | 113 |
| Macao SAR | 4 | 49 | 11 | 102 | 98 |
| Denmark | 5 | 9 | 13 | 105 | 100 |
| Iceland | 6 | 1 | 8 | 115 | 114 |
| Netherlands | 7 | 16 | 12 | 108 | 101 |
| Germany | 8 | 14 | 15 | 100 | 92 |
| Belgium | 9 | 17 | 21 | 92 | 83 |
| Austria | 10 | 19 | 19 | 98 | 88 |

*Nota.* Rangos obtenidos mediante la aplicación del modelo TOPSIS, donde la columna Variación indica el cambio neto absoluto entre los escenarios extremos. Elaboración del grupo a partir de la base integrada y los resultados TOPSIS bajo escenarios de sensibilidad.

## Anexo C: Repositorio del Proyecto y Código Fuente

El código fuente completo en lenguaje R, los scripts de integración de datos (`crea.df.completo.R`), el algoritmo de imputación por vecinos más cercanos (`Imputar.KNN.R`), y la función de cálculo del modelo (`Funcion_topsis.R`), se encuentran alojados en el repositorio público de GitHub para su auditoría y replicabilidad.

**Enlace de acceso:** https://github.com/AndresF-Torres/Proyecto-Herramientas-g6.git

*Nota.* El repositorio incluye los conjuntos de datos en formato `.csv` y `.xlsx` utilizados, así como un archivo `README.md` que detalla los ocho indicadores socioeconómicos, ambientales y de bienestar evaluados en este estudio.